Cuttlestrike

Stratégies de chasse de la seiche — méthodes, choix et alternatives

Du calcul des variables jusqu'aux tests statistiques et aux figures · session de référence **reference_best** · 27 octobre 2026

En bref. 173 à 200 seiches filmées pendant une capture de crevette ont été suivies image par image (DeepLabCut). Six variables de comportement par image ont été regroupées en **23 états** (clustering Leiden). Chaque individu devient une **séquence d'états** ; les séquences sont comparées par une distance composite (**SeqVec**, 9 familles), puis regroupées en **6 stratégies** (A–F) + 17 individus « MONO ». Les stratégies diffèrent sur toutes les variables de comportement testées et sur la position autour de la proie : A, B et C finissent derrière la crevette (A et B se resserrent fortement entre le départ et la frappe), D devant, E sur le côté, F sans position préférée. Une analyse séparée examine si le comportement de la crevette influence la stratégie.

Sommaire

1. Vue d'ensemble du pipeline
2. Données et calcul des variables
3. Clustering des images en états (Leiden)
4. Séquences et distance SeqVec
5. Groupes de stratégies
6. Profils et médoïdes
7. Organisation du code et des sessions
8. Figures de résultats
9. Statistiques : choix des tests
10. Figures de publication
11. Analyse de la crevette
12. Limites et pistes

1. Vue d'ensemble du pipeline

L'analyse part des coordonnées DeepLabCut de chaque vidéo et aboutit à des stratégies de chasse, décrites puis comparées statistiquement. Chaque étape est faite par un script ou un notebook du dossier **Code/** ; les résultats d'une exécution complète sont sauvegardés comme une **session** (dossier **Results/<nom>/**) que les notebooks suivants rechargent sans rien recalculer.

Étape	Où	Sortie
Variables par image (seiche)	add_features_full.py	Data/cut_cuttlefish_with_new_features_smooth_1.csv
Variables par image (crevette)	add_features_shrimp.py	Data/shrimp_features_smooth_1.csv
États (Leiden), séquences, SeqVec, groupes, regroupement, sauvegarde	1_compute.ipynb	Results/<session>/
Caractérisation du modèle (UMAP, états, médoïdes, explication des groupes)	2_model.ipynb	figures_2_model/
Figures de résultats, statistiques, figures de publication	3_results.ipynb	figures_3_results/
Outils interactifs (explorateur, vidéos, séquences, simulateur)	4_interactive.ipynb	fenêtres
Influence de la crevette sur la stratégie	5_shrimp_impact.ipynb	figures_5_shrimp_impact/

Les notebooks complets **all_cuttlefish** (FR) et **all_cuttlefish_english** contiennent tout en un seul fichier ; les notebooks 1 à 5 en sont le découpage, et toute modification est reportée dans les deux.

2. Données et calcul des variables

2.1 Source

Tracking DeepLabCut de chaque vidéo (points de la seiche : Apex, TopMantle, yeux, bras... ; de la crevette : HeadShrimp, MidShrimp, TailShrimp). L'Excel **Data_cuttlfish_strike.xlsx** donne, par individu, l'image du début de l'activité de la seiche (**Frame_start**), l'image de la frappe (**Catch_frame_nb**), l'échelle (mm par pixel) et le fps. L'analyse de la seiche porte sur le segment **Frame_start → frappe** (fichier « cut »).

2.2 Nettoyage

- **Sauts de tracking** : chaque position est comparée à la dernière position valide (et non à l'image précédente), avec un déplacement maximal de 50 px par image ; au-delà de 30 images, la nouvelle position est acceptée. Les positions rejetées sont interpolées.
- **Inversions tête ↔ milieu de la crevette** (crevette repliée) : si la longueur tête-milieu tombe sous 60 % de sa valeur habituelle, l'axe de la crevette est rejeté puis interpolé.
- **Bruit** : vitesses < 0,5 mm/s mises à 0 ; variations d'angle < 0,15°/image ignorées.
- **Lissage** : fenêtre de 1 image retenue (10 et 30 ont été calculées mais ne sont pas utilisées).

2.3 Les six variables du clustering

Variable	Ce qu'elle mesure	Pourquoi
distance_to_shrimp	distance seiche–crevette (log)	proche ou loin de la proie
attack_side	où est la seiche autour de la crevette : 0° = devant sa tête, 180° = derrière	remplace approach_angle (orientation relative des corps), moins interprétable
bearing_to_prey	la seiche vise-t-elle la proie ? 0° = droit devant	orientation de la seiche
cuttle_approach_speed	la seiche avance vers la proie (+) ou recule (−), log signé	isole le mouvement de la seiche
orbit_speed	la seiche tourne autour de la proie (°/s, log)	comportement de contournement

Variable	Ce qu'elle mesure	Pourquoi
who_moves	log(1+v seiche) − log(1+v crevette)	qui bouge : seiche, crevette, les deux

orbit_speed a été redéfini : l'ancienne version comptait comme « orbite » une ligne droite passant à côté de la proie (36 % des fortes valeurs). La nouvelle ne compte l'angle balayé autour de la proie que si la trajectoire de la seiche tourne dans le même sens (minimum des deux sur 20 images, lissé sur 0,5 s).

2.4 Alternatives explorées

- **Anciennes variables** (« cut_old », 5 variables : distance, approach_angle, vitesse, orientation_variation, jerk) — remplacées : vitesse et orientation_variation étaient corrélées (r = 0,79), approach_angle peu interprétable.
- **Fichier complet** (« full », Start → frappe, ~1,2 M images, Leiden sur 1 image sur 3) — possible mais non retenu : le segment avant Frame_start ne fait pas partie de la chasse.
- **Seuil d'orbite** (ORBIT_MIN_DEG_S) : 8 °/s testé, il dégradait les groupes (un seul état d'orbite) → 0 retenu.
- Variables retirées du clustering mais gardées pour décrire : vitesse de la seiche, vitesse et recul de la crevette, variation de distance (mélange seiche + crevette, r = 0,87 avec le recul de la crevette).

3. Clustering des images en états (Leiden)

Chaque image est un point dans l'espace des 6 variables. Les variables sont d'abord **standardisées** (écart-type 1), puis **pondérées** : multiplier une variable par W après standardisation lui donne exactement W fois plus d'importance dans la distance entre images (avant standardisation, l'effet d'un poids dépendrait de l'unité). On construit le graphe des **K = 300** plus proches voisins et on y cherche des communautés avec l'algorithme **Leiden** (résolution 1,0).

Paramètre	Valeur	Raison
Poids	attack_side 3 · approach 2 · orbit 5 · who_moves 4 · distance 1 · bearing 1	faire séparer les états par le MOUVEMENT plutôt que par la seule position
K, résolution	300, 1,0	K = 300 donne des états plus homogènes que K = 1000 ; résolution 1,0 sépare mieux l'orbite
Niveau 2	Leiden sur les centroïdes des états (K2 = 3, rés. 5)	11 « superclusters » regroupant les états proches
Exclus	individus 152 et 133	152 : fichier cut anormal (4314 images au lieu de ~251) ; 133 : absent de l'Excel ; chacun créait ses propres états
Résultat	23 états (C0–C22), 11 superclusters	90 274 images, 200 individus

Une projection **UMAP** des images sert uniquement à la visualisation (2_model). Les états sont décrits par leurs valeurs moyennes (radars, profils) dans 2_model.

4. Séquences et distance SeqVec

Chaque individu devient la suite de ses états au cours de la chasse. Les segments de moins de **15 images** (0,25 s) sont retirés (bruit de clustering) ; 17 individus restent dans un seul état et sont classés « **MONO** ».

Pour comparer deux individus, la distance **SeqVec** combine 9 familles de descripteurs. Chaque famille est ramenée à la même échelle (normalisation par sa valeur typique) puis pondérée : $D^2 = \Sigma\, w_f \cdot (D_f / \text{échelle}_f)^2$, si bien que chaque famille pèse $w_f/\Sigma w$ quel que soit son nombre de colonnes.

Famille	Question	Poids
hist	combien de temps dans chaque état ?	1

Famille	Question	Poids
temporal	quels états dans la 1re et la 2e moitié de la chasse ?	1
lastapp	quels états juste avant la frappe ?	1
duration	durée totale de la chasse	0,5
align	l'ordre des états est-il semblable ? (substitution peu coûteuse entre états proches)	1
dynamics	les variables évoluent-elles de la même façon ? (DTW sur les séries)	1
speed	vitesse moyenne de la seiche	0,5
path	distance totale parcourue	1
start	distance à la proie au départ	1

Choix et alternatives

- **path** et **start** ont été ajoutées à la demande (distance parcourue, distance de départ), d'abord avec un poids 0,5 puis 1 dans la session de référence : elles aidaient à replacer des individus mal classés.
- **duration** et **speed** à 0,5 : informatives mais redondantes avec path (distance = vitesse × durée).
- Les familles « douces » (hist, temporal) tiennent compte de la similarité entre états : deux états proches ne comptent pas comme totalement différents.
- Un outil de diagnostic (2_model) mesure ce que chaque famille apporte à la séparation des groupes.

5. Groupes de stratégies

Les individus sont reliés à leurs **10 plus proches voisins** selon la distance SeqVec, puis l'algorithme Leiden cherche les communautés de ce graphe (modularité). Un **regroupement optimal** fusionne ensuite les groupes trop petits pour une puissance statistique suffisante : taille minimale calculée pour un effet d = 0,75 (α = 0,05, puissance 0,95) → **n ≥ 12**, en fusionnant toujours les deux groupes les plus proches (distance SeqVec moyenne) et en refusant une fusion si d > 0,8. Les groupes reçoivent ensuite des lettres.

Groupe	A	B	C	D	E	F	MONO
Individus	44	32	31	27	26	23	17

Qualité. La silhouette globale est faible (+0,11) : les stratégies forment plutôt un **continuum** avec des noyaux nets qu'une partition franche. Les individus de silhouette négative (mieux placés dans un autre groupe) sont listés dans les tableaux d'explication des groupes. D'autres indicateurs sont disponibles : modularité, pureté des voisins, stabilité par bootstrap (ARI), η^2 et V de Cramér avec le type de capture.

Alternatives explorées

- **Classification hiérarchique de Ward** avec choix du nombre de groupes par silhouette — disponible dans l'explorateur, non retenue (impose des groupes compacts et sphériques).
- **Séquences sur les 11 superclusters** au lieu des 23 états (session Test_supersluster) : 7 groupes ; 74 % des individus restent dans le groupe correspondant (ARI = 0,56). L'ancien A se coupe en deux (23 + 17 individus) ; les individus qui changent ont presque tous une silhouette faible ou négative.
- Plusieurs valeurs de K et de résolution, avec ou sans path/start, ont été comparées dans l'explorateur interactif.

6. Profils et médoïdes

Pour chaque stratégie, le **médoïde** est l'individu réel le plus représentatif : celui dont la somme des distances DTW aux autres membres est minimale. La DTW est calculée sur les séquences **compressées** (un élément par segment, durées ignorées, tous les états également distants). Le médoïde décrit donc l'**ordre** typique des états.

La figure « probabilité d'être dans chaque état au cours du temps » est différente : c'est une moyenne sur tous les membres, en temps normalisé, lissée. Un médoïde ne suit donc pas forcément l'état le plus probable à chaque instant. Alternatives proposées, non implémentées : séquence consensus (état le plus probable à chaque instant), médoïde « temporel » (le membre le plus proche de ce consensus) ou médoïde selon la distance SeqVec.

7. Organisation du code et des sessions

- **1_compute** calcule tout sans figure et sauvegarde une session (sauvegarde protégée par DO_SAVE = False pour qu'un « Run All » n'écrase rien). Les notebooks 2 à 5 rechargent la session (LOAD_NAME).
- Chaque figure affichée est enregistrée automatiquement dans le dossier de la session chargée (figures_2_model, figures_3_results, figures_5_shrimp_impact).
- Affichage : fenêtres l'une après l'autre (WAIT_FOR_CLOSE) ou plusieurs à la fois ; mode inline possible.
- Variable **SUBJECT** (cuttle / shrimp) dans la cellule 0 : le même pipeline s'applique à la crevette ; les dossiers de vidéos courtes (videos_catch) et longues (01_VIDEO_Cropped) sont choisis selon la session.
- Outils interactifs : explorateur SeqVec, UMAP, cartes 3D, mosaïque vidéo, lecteur vidéo (avec la stratégie de l'individu), navigateur par stratégie, liste défilante des séquences par groupe, simulateur comportemental.

8. Figures de résultats (3_results)

- **Variables au cours du temps** : temps normalisé 0–1 par individu (chasses de durées différentes), moyenne ± écart-type.
- **Comparaisons** : distributions, heatmap des moyennes, radars, significativité par paire.
- **Puissance** : taille d'effet entre groupes et N minimum.
- **Trajectoires** dans l'arène par stratégie.
- **Polar plots** de la position à la frappe et au départ. Convention unifiée avec attack_side : **0° = devant, 180° = derrière** (l'angle de l'Excel, 0° = derrière, est tourné de 180°). La position au départ n'existe pas dans l'Excel : elle est calculée depuis le tracking avec la même convention ; vérifiée à la frappe, elle concorde avec l'Excel à 8° près (médiane).
- **Types de capture** par stratégie.

9. Statistiques : choix des tests

Toutes les comparaisons entre stratégies sont regroupées dans une seule cellule **STATISTICS** de 3_results, en 8 sections : réglages, fonctions, données (une ligne par individu), pré-tests, tests globaux, post hoc, tests appariés départ → frappe, correction des p, fichiers. Unité statistique : l'**individu** (une chasse par seiche, observations indépendantes). Permutations : 9 999 ; bootstrap : 2 000 ; p = (1 + nombre de valeurs nulles ≥ observée) / (B + 1).

9.1 Variables continues (distances, durée, vitesse, approche, orbite)

Choix	Pourquoi	Alternatives considérées
Kruskal-Wallis, puis Mann-Whitney par paire, BH	Normalité rejetée dans la plupart des groupes (Shapiro) et variances inégales (Levene) pour presque toutes les variables.	ANOVA ; ANOVA de Welch ; choix automatique selon les pré-tests (utilisé au début, abandonné).
Test fixé a priori, pré-tests seulement rapportés	Choisir le test d'après un pré-test est déconseillé (le résultat du pré-test influence l'erreur de type I).	—
Mann-Whitney + BH comme post hoc	Simple, robuste, conclusions proches de Dunn.	Test de Dunn (le post hoc classique après Kruskal-Wallis) : proposé, non appliqué.
Interprétation	Quand les dispersions diffèrent, Kruskal-Wallis compare des distributions (une stratégie tend à avoir des valeurs plus grandes), pas des médianes. Les histogrammes par groupe montrent des formes semblables pour la plupart des variables, mais pas pour % immobile, durée, approche.	—

9.2 Position autour de la proie (angle)

Question	Test retenu	Alternatives
La position diffère-t-elle entre stratégies ?	Statistique de Watson-Williams, p par permutation des étiquettes. H0 = distributions identiques : une différence peut venir de la direction ET/OU de la concentration.	Watson-Williams paramétrique (conditions non remplies : groupes sans direction préférée, $\bar{R}$ = 0,35 au départ, dispersions inégales). MANOVA robuste sur (cos θ, sin θ) — MATS de Friedrich & Pauly (2018), R MANOVA.RM — recommandée par la relecture, non implémentée (R non installé). Watson U^2 par paires.
Quelles paires ?	Même statistique par paire (9 999 permutations), BH. Une paire avec un groupe sans position préférée (Rayleigh n.s.) est marquée † : ce sont les distributions qui diffèrent, pas les positions.	500 permutations au début (trop peu près du seuil BH ≈ 0,003).
Les directions moyennes diffèrent-elles ?	Seulement entre groupes orientés (Rayleigh p < 0,05) : IC bootstrap de μi − μj, chaque groupe rééchantillonné séparément (aucune hypothèse de distributions ou κ égaux), p circulaire, BH.	—
La dispersion diffère-t-elle ?	Wallraff (Kruskal-Wallis sur l'écart à la moyenne du groupe) et écart des R entre groupes, par permutation **recentrée** (chaque groupe tourné à 0°, pour que les différences de direction ne gonflent pas la dispersion).	Wallraff avec le p classique (biaisé : l'écart est mesuré à une moyenne estimée sur les mêmes données).

9.3 Resserrement entre le départ et la frappe (mêmes individus)

- Indice : **R** (longueur du vecteur moyen ; 0 = dispersé, 1 = tous au même angle). R surestime la concentration dans les petits échantillons ($E[R^2] = \rho^2 + (1 - \rho^2)/n$), surtout quand elle est faible : on utilise **R corrigé** = $\sqrt{((n \cdot R^2 - 1)/(n - 1))}$.
- **Test par échange apparié** : sous H0, les deux angles de chaque individu sont échangés au hasard (9 999 fois) ; IC **BCa** (le percentile se comporte mal près de 0) ; BH sur les 6 stratégies.

- ΔR ne mesure que le resserrement. Le **déplacement** de position est testé à part sur les changements individuels Δθ = θ frappe − θ départ (moyenne circulaire, IC bootstrap, Rayleigh).
- **Sensibilité** : l'angle à la frappe est recalculé depuis le tracking (au lieu de l'Excel) ; les conclusions sont inchangées. Un biais constant entre méthodes change μ, pas R ; un bruit de ~8° réduit R d'environ 1 %.
- Alternative initiale : ΔR brut avec IC percentile (conservateur à cause du biais de R).

9.4 Type de capture

χ^2 stratégie × type de capture ; 56 % des effectifs attendus sont < 5 → p par permutation ; taille d'effet : V de Cramér.

9.5 Corrections multiples (Benjamini-Hochberg)

Trois niveaux : sur l'ensemble des variables (tests globaux), à l'intérieur de chaque variable (paires), sur les 6 stratégies (tests appariés).

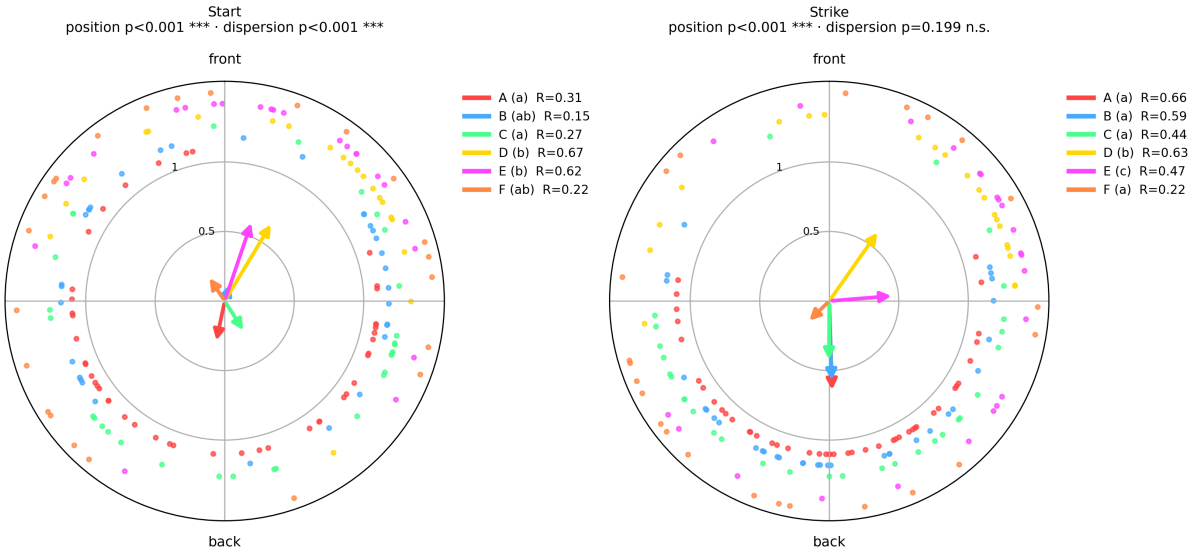
9.6 Résultats principaux (reference_best)

Mesure	Résultat
Variables de comportement	toutes diffèrent (p BH ≤ 0,001) ; effets : distance au départ et distance parcourue ε^2 = 0,60, vitesse 0,50, approche 0,45, orbite 0,43, distance moyenne 0,33, durée et % immobile 0,28, distance à la frappe 0,09
Position au départ	diffère (p < 0,001) ; directions : A ≠ D et A ≠ E (≈ 160–175° d'écart) ; seuls A, D, E orientés
Position à la frappe	diffère (p < 0,001) ; A, B, C derrière (≈ 180°, entre eux n.s.), D devant (≈ 325°), E sur le côté (≈ 275°), D ≠ E ; F sans position préférée (Rayleigh p = 0,32)
Dispersion	au départ elle diffère (Wallraff p < 0,001) ; à la frappe Wallraff n.s. (p = 0,20) mais l'écart des R reste significatif (p = 0,03), surtout à cause de F
Resserrement	A : ΔR = +0,37 [+0,22 ; +0,64] ; B : +0,58 [+0,36 ; +0,80] (p BH < 0,001) ; C, D, E, F n.s. (D et E déjà concentrés au départ)
Déplacement Δθ	aucun significatif
Type de capture	lié à la stratégie (p < 0,001, V = 0,40)

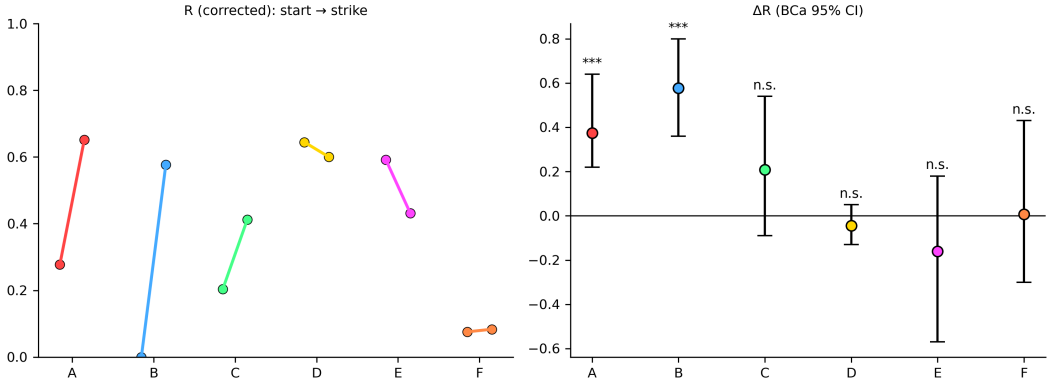
Circularité. Les stratégies ont été formées à partir de certaines de ces variables (vitesse, distance parcourue, distance de départ, via SeqVec). Les tests confirment surtout que les groupes sont bien séparés sur ces variables. Les tests réellement indépendants du clustering sont la position à la frappe (mesurée dans l'Excel) et le type de capture.

10. Figures de publication

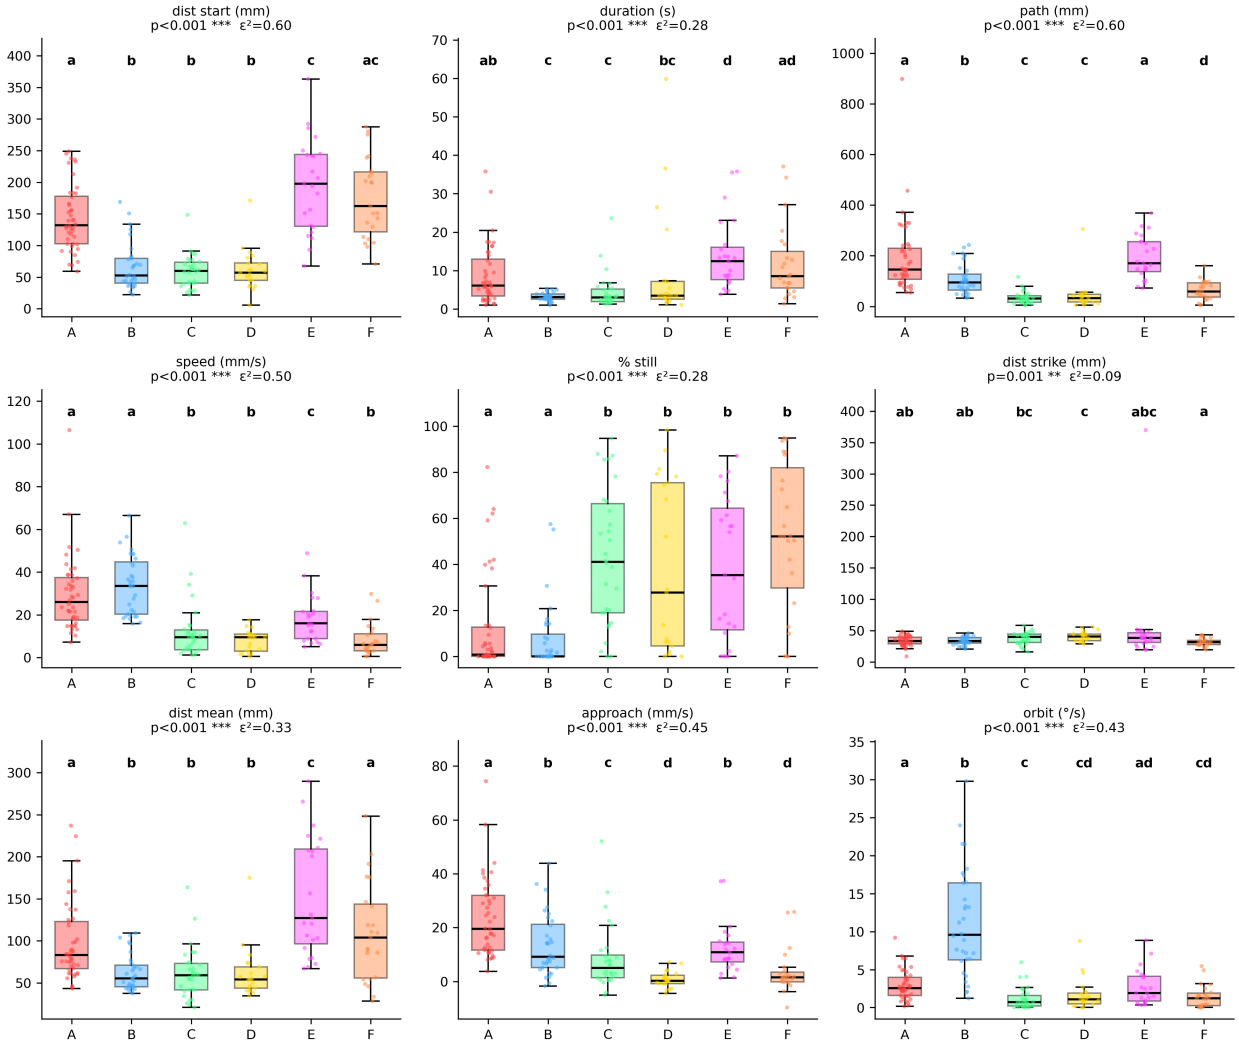
- Fond blanc, PNG 300 dpi + PDF, dans figures_3_results/publication/.
- **Lettres** au-dessus des groupes (affichage compact) : deux stratégies sans lettre commune diffèrent. Choisies plutôt que des barres avec astérisques, illisibles avec 10 à 13 paires significatives (option « brackets » disponible).
- Boîtes à moustaches + points individuels (option : moyenne ± IC 95 % bootstrap).
- Position : flèche par stratégie (direction moyenne, longueur = R), individus en périphérie.
- Diagnostics : QQ-plots des résidus, résidus par groupe (homoscédasticité), histogrammes par groupe et comparaison des formes.



Position autour de la proie au départ et à la frappe (flèche = direction moyenne, longueur = R).



Resserrement de la position : R corrigé au départ et à la frappe, ΔR avec IC BCa à 95 %.



Variables de comportement par stratégie (Kruskal-Wallis ; lettres = post hoc Mann-Whitney, BH).

11. Analyse de la crevette

11.1 Variables

add_features_shrimp.py calcule, à partir du tracking complet, de 30 s avant le début de l'activité de la seiche jusqu'à la frappe (colonne **phase** : « pre » / « hunt ») : vitesse, pics d'accélération (départs brusques, seuil au percentile 99, ≥ 0,25 s d'écart), sens de nage (vitesse projetée sur l'axe du corps), vitesse angulaire, angle de la seiche vue par la crevette, distance, et la vitesse de la seiche. Tracking de bonne qualité (< 1 % de points peu fiables). 71 individus ont moins de 30 s avant l'activité de la seiche (durée réelle conservée).

Choix : une seule analyse avec la phase marquée (et non deux analyses séparées) ; la distance est gardée car informative même si elle dépend aussi de la seiche ; l'accélération continue est exclue du clustering (r ≈ 0,9 avec la vitesse) au profit du taux de pics.

11.2 Comportements de la crevette

Avec SUBJECT = « shrimp », 1_compute donne 28 états, 12 superclusters et **4 groupes** de crevettes (session de test). Le début de l'activité de la seiche est marqué (ligne cyan) sur les figures temporelles et les outils interactifs.

11.3 Influence sur la stratégie (5_shrimp_impact)

Analyse	Résultat
Mouvement propre de la crevette avant l'activité → prédire la stratégie	pas mieux que le hasard : précision équilibrée 0,23 (hasard 0,17), permutation p = 0,065

Analyse	Résultat
Avec la position relative (distance, angle)	0,46–0,50, p = 0,005, mais en partie circulaire (la distance de départ sert aussi à former les stratégies)
Groupes crevette × stratégies seiche	association modérée (V ≈ 0,36–0,39)
Distance au début de l'activité	sépare fortement les stratégies (η^2 = 0,58) : E, F loin ; B, C, D proches ; A intermédiaire

11.4 Corrélation des vitesses seiche / crevette

Corrélation croisée et latence entre pics de vitesse, par individu et par stratégie. Première version en secondes absolues autour du début de l'activité : **abandonnée**, car les chasses durent de 1 à 60 s (médiane 4,8 s) et les individus « disparaissent » au fil du temps. Version retenue : **phase de chasse seule, temps normalisé** 0 (seiche active) → 1 (frappe), décalages explorés ± 1 s. Résultat : les stratégies diffèrent (Kruskal-Wallis p = 0,005) ; en D et E la seiche suit la crevette avec ~0,6–0,9 s de retard (p < 0,01) ; en F aucun couplage.

12. Limites et pistes

- Groupes en continuum (silhouette 0,11) : les frontières entre stratégies sont floues pour une partie des individus.
- Circularité partielle des tests sur les variables ayant servi au clustering.
- Angle à la frappe mesuré dans l'Excel et angle au départ par le tracking (sensibilité vérifiée) ; préciser si l'annotateur connaissait la stratégie.
- À faire si besoin : MATS (R MANOVA.RM) pour le test global de position ; test de Dunn ; médoïde temporel ; session crevette définitive ; tests de puissance par variable.
- Fichiers lourds (tracking complet, sessions crevette) gardés en local, hors GitHub (limite de 100 Mo).